

통신망 장애 사전 예방을 위한 통신사업자의 노력과 예지보전 AI 기술의 적용 방안

김은도
KT

요약

본고에서는 다양하고 많은 이기종 통신 장비들로 구축되어 있어 유지관리 복잡도가 매우 높은 통신사업자의 대규모 유무선 통신망에서 장애 사전 예방을 위한 통신사업자의 노력과 이를 해결하기 위한 예지보전 AI 기술의 적용 방안에 대해 알아보고자 한다. 먼저, 장애 관제를 어렵게 만드는 요소에 대해서는 상호 표준화되지 않고 제조사 종속적인 형식 및 운용 환경 차이를 예로 들어 설명한다. 다음으로는 이를 해결하기 위한 전통적인 규칙 기반 장애 관제 기술에 대해 사전 정의 방식과 고정 임계치 활용 방식을 통해 살펴본 뒤, 더욱 진보된 AI 기반 장애 관제 기술에 대해 시계열 데이터의 정교한 분석과 동적 임계치 활용 방식 측면에서 설명한다. 마지막으로, AI 기술의 발전과 함께 최근 각종 분야에서 화두가 되고 있는 예지보전 기술의 적용을 위한 회귀 분석에 대해 소개하고 나서 통신사업자 관제 지능화 솔루션의 향후 발전 방향에 대해 모색한다.

I. 서론

통신사업자의 유무선 통신망은 다양하고 많은 이기종 통신 장

비들로 구축 및 운용되고 있어 유지관리가 매우 중요하다. 통신망 관리 부실로 인한 품질의 저하는 고객 신뢰도 경감 또는 고객 이탈과 같은 심각한 문제로 이어질 수 있으므로, 통신사업자는 안정적인 통신망 구축과 재빠른 장애 대응을 위한 관제 업무에 많은 노력을 기울이고 있다.

하지만 <그림 1(a)>와 같이 장비군 각각은 제조사마다의 전용 EMS(Element Management System)를 통해 개별 설정 및 관리되어야 하므로 운용자는 전용 EMS별 서로 다른 도메인 지식과 사용법을 습득해야만 한다. 또한, 이는 곧 통신망의 유지관리를 복잡하게 만드는 요인이 된다[1]. 이처럼 사람에 의한 전통적인 통신망 관제와 장애 사후 대응은 운용자의 과도한 수작업을 유발하며, 심각한 경우 VoC(Voice of Customers) 발생 전에는 장애를 인지하지도 못하는 상황까지 초래하게 될 수도 있다. 이러한 문제를 해소하기 위해, 통신사업자에서는 <그림 1(b)>와 같이 통신망 통합 관제 시스템을 자체 도입하여 장비 제조사마다의 파편화된 전용 EMS로 인한 어려움 없이 통신망을 효율적으로 관제할 수 있게 되었다. 이외에도 통신사업자는 안정적인 통신망의 유지관리를 위해 보다 혁신적이고 성능이 개선된 관제 시스템 구축에 많은 투자를 할뿐만 아니라 숙련된 운용자를 양성하기 위한 다양한 노력도 기울이고 있다.

본고에서는 통신망에서 발생 가능한 장애를 사전에 예방하거나 이미 발생한 장애를 정확히 분석하여 재발을 막기 위한 통신

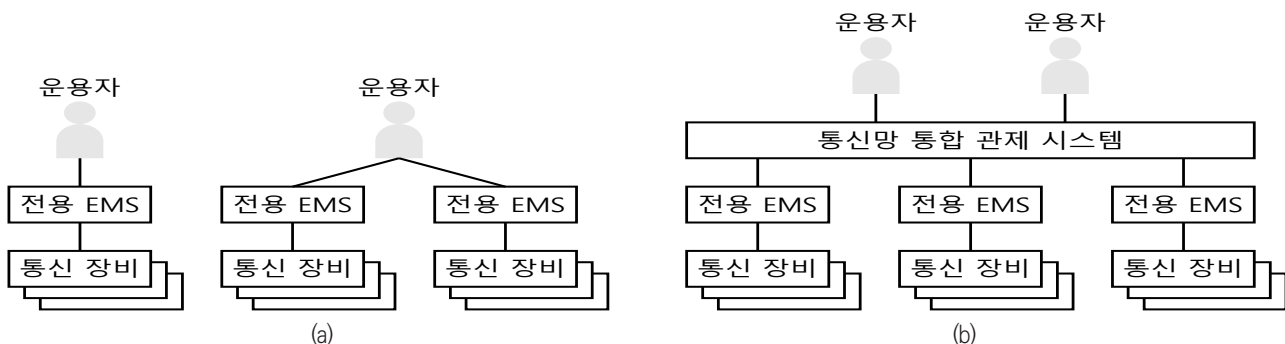


그림 1. (a) 통신 장비 제조사별 전용 EMS를 통한 통신망 운용자의 이기종 통신 장비 관제 방식;
(b) 통신사업자의 이기종 통신 장비 통합 관제 시스템 도입을 통한 통신망 운용자의 효율적 관제 방식

사업자의 솔루션에 대해 알아보고자 한다. 먼저, II장에서는 통신사업자의 대규모 통신망 내에서 장애 관제를 어렵게 만드는 요소들은 무엇이 있는지 설명한다. 다음으로, III장에서는 통신사업자의 전통적인 규칙 기반(Rule-based) 장애 관제 기술에 대해 살펴본 뒤, IV장에서는 더욱 진보된 AI 기반(AI-based) 장애 관제 기술에 대해 설명한다. 이어서 V장에서는 AI 기술의 발전과 함께 최근 각종 분야에서 화두가 되고 있는 예지보전(Predictive Maintenance) 기술의 적용 방안에 대해 소개한다. 마지막으로, VI장에서는 본고에서 서술한 전체적인 내용을 요약하며, 통신사업자 관제 지능화 솔루션의 향후 발전 방향에 대해 모색한다.

II. 통신망 장애 관제의 어려움

앞서 살펴봤듯이, 통신망은 다양하고 많은 이기종 통신 장비들로 구축되어 있으며, 이러한 환경에서 통신사업자는 장비 제조사별 파편화된 전용 EMS로 인한 불편을 해소하기 위해 통합 관제 시스템을 도입하는 등의 노력을 기울이고 있다. 하지만 안정적인 통신망 유지관리를 위한 통신사업자의 이러한 노력에도 불구하고, 통신망 장애 관제를 어렵게 만드는 다양한 요소들이 여전히 존재한다.

먼저, 이기종 통신 장비군 각각은 상호 표준화되지 않고 제조사 종속적인 서로 다른 경보 메시지 형식을 가지고 있어 분석에 어려움이 따른다[2]. 예를 들어, 장비의 전원부 이상을 나타내는 경보 메시지는 제조사별로 "Power Failure", "POWER_SHUTDOWN", "PSU-FAIL" 등에 이르기까지 매우 다양하다. 이는 <그림 1(b)>에서 살펴봤던 통신망 통합 관제 시스템을 구축하는 데 있어서도 허들 포인트로 작용한다.

또한, 동일한 장비라 할지라도 설치 위치에 따라 트래픽 발생량, 커버리지 등 운용 환경에 차이가 존재하므로 서로 다른 기준에 의해 관리되어야 한다[3]. 예를 들어, 주거 밀집 지역에서는 주로 평일 야간이나 주말에 트래픽이 증가하는 반면, 산업 단지에서는 평일 주간에 한해 트래픽이 증가하는 경향을 볼 수 있다. 즉, 주거 밀집 지역에서 평일 야간에 트래픽이 증가하는 것은 자연스러운 현상이나, 산업 단지에서 해당 시간에 트래픽이 증가한다면 이상 현상이라 간주하는 등의 정교한 기준 수립이 필요하다.

다음 장에서는 이처럼 통신망 장애 관제를 어렵게 만드는 요인을 해소하기 위해 통신사업자에서 수행하는 전통적인 규칙 기반 장애 관제의 몇 가지 기술에 대해 소개한다.

III. 전통적인 규칙 기반 장애 관제 기술

통신사업자의 대규모 통신망 내에서 다양하고 많은 이기종 통신 장비들로 인한 문제를 해결하기 위한 한 가지 방법은 발생 가능한 모든 상황을 사전에 분석하여 규칙으로 정의해 두는 것이다[4]. 이와 같은 방법론을 규칙 기반 방식이라 하며, 가장 단순하지만 정확한 방법이기도 하다.

<표 1>은 파편화된 통신 장비 제조사로부터의 다양한 장비에서 발생 가능한 주요 경보 메시지를 일괄 가지 항목으로 사전 분류한 예시를 보여준다. 미리 분석된 해당 표를 참고하여 통신망

표 1. 통신 장비 제조사별 파편화된 주요 경보 메시지의 7대 분류 예시

경보 메시지	분류 유형	경보 메시지	분류 유형
48V-[A,B]-FAIL	전원 장애	NVRAM-FAIL	유니트 장애
BATT-EXPIRED	전원 장애	NVRAM-PBANK1-FAIL	유니트 장애
BATTERY-REMOVE	전원 장애	NVRAM-TBANK1-FAIL	유니트 장애
BATT_FULLY_DISCHARGE	성능 이상	OPTIC_RX_HI_PWR	성능 이상
BATT_LOW	성능 이상	OPTIC_RX_LO_PWR	성능 이상
BATT_UNEQUIP	전원 장애	OPTIC_TEMPERATURE_HI	성능 이상
BP_IPC_FAIL	유니트 장애	OPTIC_TEMPERATURE_LO	성능 이상
CPU-LOAD-HIGH	성능 이상	OPTIC_TX_HI_PWR	성능 이상
CPU_HEALTH_ALM	성능 이상	OPTIC_TX_LO_PWR	성능 이상
DC_[A,B]-FAIL	전원 장애	OPT-LOS	링크 장애
DS[1,1E]-LOS	회선 장애	OPT-PWR-HIGH	성능 이상
ETH-ERR	성능 이상	OPT-PWR-LOW	성능 이상
ETH-LINK-FAIL	링크 장애	OPT-REMOVE	유니트 장애
ETH_PORT_REMOTE_FAULT	통신 장애	PDH-LOS	회선 장애
ETH_SD	성능 이상	PSU-[A,B]-FAIL	전원 장애
EXTCK-AIS	클럭 장애	PSU-[A,B]-REM	전원 장애
EXTCK-EBER	클럭 장애	PTLMI-[1,2,3,4]-FAIL	유니트 장애
EXTCK-LOF	클럭 장애	PW-CSF	회선 장애
EXTCK-LOS	클럭 장애	PW-LOC	회선 장애
EXT_[A,B]_AIS	클럭 장애	PW-RDI	회선 장애
EXT_[A,B]_EBER	클럭 장애	PW_LOC	회선 장애
EXT_[A,B]_LOF	클럭 장애	PW_OAM_CSF	회선 장애
EXT_[A,B]_LOS	클럭 장애	PW_OAM_CSF_FDI	회선 장애
FAN-[1,2,3]-FAIL	유니트 장애	PW_OAM_CSF_RDI	회선 장애
FAN-48[A,B]-FAIL	전원 장애	PW_RDI	회선 장애
FAN-[F,R]-CR	유니트 장애	QL-FAIL	클럭 장애
FAN-[F,R]-FAIL	유니트 장애	SMA_LOS	클럭 장애
FAN_M[1,2]_FAIL	유니트 장애	SMA_REF_FAIL	클럭 장애
FAN1_SPEED_OFF_FAIL	유니트 장애	TDM-PW-RMT-FAIL	회선 장애
FUSE-[A,B]-FAIL	전원 장애	TUNNEL_LOC	링크 장애
LINK-FAIL-LLCF	회선 장애	TUNNEL_RDI	링크 장애
Link_Down	링크 장애	UNIT-FAIL	유니트 장애
LLCF_LINK_DOWN_REQ	회선 장애	UNIT-HIGHTEMP	성능 이상
LOS	링크 장애	UNIT-REM	유니트 장애
LSP-LOC	링크 장애	UNIT_FAIL	유니트 장애
MEMORY_HEALTH_ALM	성능 이상	UNIT_HIGH_TEMPERATURE	성능 이상
MEM-LOAD-HIGH	성능 이상	UNIT_LOW_TEMPERATURE	성능 이상
MGMT-OV	링크 장애	UNIT_OUT	유니트 장애
MODULE_OUT	유니트 장애		(경보 메시지 ABC 순)

운용자는 장비 제조사별 서로 다른 도메인 지식 없이도 쉽게 경보 메시지에 대한 해석이 가능하다. 하지만 이러한 규칙 기반 방식에도 분명한 한계는 존재하는데, 만약 사전 정의되지 않은 상황이 발생했을 때는 결과를 도출할 수 없다는 것이다. II장에서 예로 들었던 장비의 전원부 이상을 나타내는 경보 메시지만 "Power Failure", "POWER_SHUTDOWN", "PSU-FAIL"에 대한 규칙을 사전 정의했다고 가정해 보자. 이 때, 만약 "PWR_FAIL", 심지어는 매우 유사한 형태인 "Power Fail"이라는 경보 메시지가 발생해도 기존의 규칙을 적용할 수 없다는 문제가 생긴다. 특히 신규 통신 장비의 도입이 빈번한 통신사업자의 경우에는 발생 가능한 모든 상황을 사전 정의한다는 것이 현실적으로 불가능에 가깝기 때문에, 이는 결과적으로 잦은 유지보수로 인한 번거로움을 동반하게 될 수도 있다.

규칙 기반 방식의 또 다른 예로는 임계치를 활용하여 주로 수치형 시계열 데이터(Time Series Data)의 이상을 탐지하는 것이 있다. 이 방법은 특정 시간대의 값이나 시간의 흐름에 따른 값의 변화량이 사전 설정해 둔 임계치 이상 또는 이하가 된다면 경보를 발생시키는 소위 TCA(Threshold Crossing Alert) 형태로 구현된다[5]. <그림 2>는 이러한 임계치 활용의 두 가지 유형을 보여준다. 먼저, <그림 2(a)>는 수치형 시계열 데이터의 흐름 내에서 특정 시간대의 값이 상한 임계치와 하한 임계치를 각각 벗어났을 때 경보를 발생시키는 상황을 나타낸다. 이 때, 보다 정교한 경보 분류를 위해 긴급 경보(Critical Alarm), 주요 경보(Major Alarm), 일반 경보(Minor Alarm) 등 단계적으로 임계치를 설정하기도 하며, 필요에 따라 상하한 임계치 중 하나만 사용하기도 한다. 다음으로, <그림 2(b)>는 수치형 시계열 데이터의 흐름 내에서 시간의 흐름에 따른 값의 변화량이 임계치를 벗어났을 때 경보를 발생시키는 상황을 나타낸다. 이 때도 마찬가지로, 보다 정교한 경보 분류를 위해 단계적으로 임계치를 설정하기도 하며, 필요에 따라 하나의 임계치만을 사용하기도 한다. 또한, 동일한 기준값에 대해 변화 임계치를 상한과 하한으로 구분

하여 각각을 서로 다른 변화 범위로 정의하기도 하며, 때로는 기준값 없이 단순히 최댓값과 최솟값의 차이를 변화량으로 간주하기도 한다. 이처럼 임계치를 활용하는 방식은 그 원리가 매우 간단하며 직관적인 결과를 제공한다. 하지만 임계치 활용 시에도 주의가 필요한 사항이 있는데, 그 중 대표적인 것이 아웃라이어(Outlier)를 고려해야 한다는 점이다. 통계학에서 아웃라이어란, 평균에서 크게 벗어나서 다른 표본들과 통계적으로 확연히 구분되는 값 또는 사례를 의미하는데, 이는 통계 분석의 결과를 왜곡시키거나 적절성을 해칠 수 있기 때문에 반드시 제외하거나 별도로 가공하여 사용해야 한다. 아웃라이어 탐지 및 가공 기법은 오늘날에도 AI 기술의 급격한 발전과 함께 더욱 많은 연구들이 활발히 진행되고 있는 추세다[6].

이번 장에서는 통신사업자가 통신망 장애 관제를 위해 활용 가능한 전통적인 규칙 기반 방법론에 대해 소개했다. 앞에서 언급했듯이, 이는 가장 단순하지만 정확한 방법이기에도 여전히 다양한 분야에서 널리 사용되고 있다. 하지만 명백한 한계 역시 존재하는데, 이기종 통신 장비로 구성된 환경에서 발생 가능한 모든 상황을 사전 정의하거나 다양한 운용 환경마다의 임계치 설정 기준 차이를 일일이 반영하기 힘들다는 점이다. 다음 장에서는 이러한 한계를 극복하기 위한 AI 기반 장애 관제의 몇 가지 기술에 대해 소개한다.

IV. AI 기반 장애 관제 기술의 개요

오늘날 AI 기술의 발전은 통신망 장애 관제의 영역에서도 크게 기여하고 있다. 대표적으로는, 통신망 내에서 가장 많은 부분을 차지하는 데이터인 시계열 데이터에 대한 더욱 정교한 접근을 가능하게 만들었다. 시계열 분해(Time Series Decomposition) 기법을 통해 얻을 수 있는 시계열 데이터의 네 가지 주요 성분은 다음과 같다[7].




그림 2. (a) 상한 임계치와 하한 임계치에 의한 경보 발생; (b) 변화 임계치에 의한 경보 발생




그림 3. (a) 고정 임계치 설정 방식을 통한 수치형 시계열 데이터 이상 탐지; (b) 동적 임계치 설정 방식을 통한 수치형 시계열 데이터 이상 탐지

- 추세성(Trend): 선형(Linear)이나 비선형(Nonlinear)으로 장기적 증가 또는 감소하는 데이터의 변동
- 순환성(Cycle): 주기를 가지지만 일정하지 않고 반복이 없는 데이터의 변동
- 계절성(Seasonality): 일정한 주기를 가지고 반복되는 데이터의 변동
- 불규칙성(Noise): 알 수 없거나 돌발적인 요인에 의해 발생하는 데이터의 변동

AI 기술을 통해 위의 네 가지 주요 성분을 학습하여 시계열 데이터의 향후 추이를 예측 가능하며, 기존의 고정 임계치(Fixed Threshold) 설정 방식에서 벗어나 실시간으로 동적 임계치(Dynamic Threshold)를 설정할 수 있다[8]. <그림 3>은 수치형 시계열 데이터의 이상 탐지(Anomaly Detection)를 위해 고정 임계치를 설정하는 방식과 동적 임계치를 설정하는 방식 간의 차이를 보여준다. 먼저, <그림 3(a)>는 수치형 시계열 데이터의 흐름에 관계없이 고정된 값을 가지는 상한 임계치를 정의한 상황을 나타내며, 특정 시간대의 값이 해당 임계치를 벗어났을 때 경보를 발생시키게 된다. 하지만 이 방식은 통신망 내 다양한 운용 환경마다의 임계치 설정 기준 차이를 일일이 반영하기 힘들기 때문에 상대적으로 범용성이 떨어진다고 볼 수 있다. 이에 반해, <그림 3(b)>는 상한 임계치를 벗어났을 때 경보를 발생시킨다는 점에서는 동일하지만 수치형 시계열 데이터의 흐름에 따라 동적 임계치를 정의하는 상황을 나타낸다. 이 방식은 과거 시계열 데이터의 추이나 이력을 학습하여 실시간으로 적절한 임계치를 계산하며, 이를 통해 통신망 내 다양한 기기종 장비 구성과 운용 환경 차이로 인한 고정 임계치 설정의 한계를 극복한다. 시계열 데이터의 네 가지 주요 성분을 예로 들어 동적 임계치 계산 시 고려할 수 있는 몇 가지 요소들을 나타내면 다음과 같다.

- 추세성: IoT 단말 증가로 인한 네트워크 트래픽 증가 등
- 순환성: 행사나 이벤트로 인한 특정 지역의 일시적 네트워크 트래픽 증가 후 복구 등

- 계절성: 평일과 주말, 낮과 밤 간의 주기적 네트워크 트래픽 변동 등
- 불규칙성: 통신 장비 고장으로 인한 네트워크 트래픽 절체 등이 밖에도 분석하고자 하는 데이터에 영향을 주는 다양한 요소 데이터를 활용할수록 더욱 정교한 동적 임계치를 계산할 수 있다. 지금까지 동적 임계치를 계산하기 위해 고려해야 할 시계열 데이터의 네 가지 주요 성분에 대해 소개했다. 하지만 아직 중요한 작업이 하나 남아 있는데, 계산한 동적 임계치가 이상 탐지에 있어 최적의 값을 보장해야 한다는 것이다. 통신 분야뿐만 아니라, 대부분의 상용 운용 환경에서는 정상 상태에 비해 이상 상태의 발생 빈도가 훨씬 드물기 때문에 정상과 이상 수집 데이터 개수에 대한 불균형 문제가 존재한다[9]. 또한, 이상 패턴이 명확하지 않은 경우가 많아 모든 이상 패턴을 사전 정의하는 것은 불가능에 가깝다. 따라서, 대개는 정상 데이터 내 값이나 패턴의 범위에서 크게 벗어났을 때를 이상이라 간주하는 것이 일반적이다. 여기에서 정상 데이터란 평시 운용 데이터를 의미한다. <그림 4>는 데이터 내 값 또는 패턴의 분포에 따른 정상과 이상의 분류 예시를 보여준다. 통계적으로 잘 구성 및 정의된 데이터는 흔히 가우시안(Gaussian)이라고도 부르는 정규 분포(Normal Distribution)를 따르며, 이 때 정규 분포에서의 신뢰




그림 4. 정규 분포를 따르는 데이터 내 값 또는 패턴에 대한 정상과 이상 분류




그림 5. 시간의 흐름에 따른 시계열 데이터 내 정규 분포 고려 대상 시간 범위의 변화 예시

구간(Confidence Interval)을 정의함으로써 이상을 탐지하는 다양한 비지도 학습(Unsupervised Learning) 기법들이 존재한다 [10]. 데이터의 정규 분포를 생성할 때는 주의해야 할 점이 있는데, 현재 시점으로부터 과거 어느 시점까지의 데이터를 계산에 넣을 것인지 잘 판단해야 한다는 것이다. 과도하게 긴 기간의 데이터를 고려하여 분포를 생성하면 장기적 추세 변화를 반영하지 못 한다는 문제가 생길 것이고, 반대로 너무 짧은 기간의 데이터를 고려하여 분포를 생성하면 주기적 변화를 반영하지 못 한다는 문제가 생길 것이다. <그림 5>는 시계열 데이터 내에서 정규 분포 생성 시 고려할 시간 범위가 시간의 흐름에 따라 어떻게 변화하는지 보여주는 하나의 예시다. 시계열 데이터의 특징을 분석하여 장기적 추세 변화와 주기적 변화 등을 모두 고려할 수 있는 적절한 범위를 정의한 뒤, 그림에서 나타난 것처럼 시간의 흐름과 함께 시프트(Shift) 시키는 것이 가장 간단하면서도 일반적인 방법이다.

다음 장에서는 전통적인 규칙 기반 장애 관제 기술의 한계를 극복하기 위한 AI 기반 장애 관제 기술의 발전과 함께 최근 각종 분야에서 화두가 되고 있는 예지보전 기술에 대해 알아본다.

V. 예지보전 AI 기술의 적용

지금까지는 잘 정의된 동적 임계치를 기반으로 시계열 데이터의 이상을 탐지하는 방법에 대해 살펴보았다. 하지만 이러한 방식은 현재 상태의 이상 여부를 사후 분석(Analysis) 가능할 뿐, 가까운 미래의 이상 발생 여부를 사전 예측(Prediction)하는 것은 불가능하다. 특정 시간대의 값이나 시간의 흐름에 따른 값의 변화량에 대한 임계치를 민감하게 설정하여 실제 장애 발생 전 미리 인지 가능하도록 구현할 수는 있지만, 이 역시 진정한 의미에서의 예측은 아니라고 볼 수 있다.

시계열 데이터의 실제 예측을 위해서는 주로 회귀(Regression) 분석 기법이 사용된다. 통계학에서 회귀 분석이란, 변수들 간의 관계성을 수학적으로 추정 및 해석하는 방법으로, 기본적으로는 표본들에 대해 오차를 가능한 한 작게 만드는 모델을 통계적으로 찾아 내는 기법이다[11]. <그림 6(a)>는 이러한 회귀 분석을 통해 과거 시계열 데이터의 이력으로부터 미래 시계열 데이터의 추이를 예측하는 상황을 보여준다. 이는 AI 기술을 기반으로 과거 수많은 이력 데이터를 학습하여 최근의 이력과 가장 유사한 값을 통해 외삽하는 방식으로 구현 가능하다. 한편, 이러한 회귀 분석 기법에 이전 장에서 설명한 동적 임계치 설정 기법을 결합하여 예지보전 기술을 구현할 수 있다. <그림 6(b)>는 예지보전 기술을 통해 가까운 미래에 장애 발생 가능성이 예측되면 실제 발생까지 이어지지 않도록 사전 대응하기 위해 경보를 발생시키는 상황을 보여준다. 현재 시점의 시계열 값과 임계치를 비교하는 것이 아닌 미래 시점의 시계열 예측값과 임계치 예측값을 비교하는 것이 예지보전 기술의 핵심이다.

예지보전 기술은 주로 수치형 시계열 데이터에 대해 적용하기 용이하다. 대규모 유무선 통신망을 유지관리하는 통신사업자 입장에서 네트워크 트래픽, IP 할당 수, 접속자 수, 전력 사용량 등의 인프라 관제에서부터 신규 상품 가입자 수 추이 분석 등의 마케팅에 이르기까지 매우 다양한 분야에 활용 가능하다. 다만,




그림 6. (a) 시계열 데이터의 회귀 분석을 통한 미래 시점의 값 예측; (b) 동적 임계치 설정과 회귀 분석의 결합을 통한 수치형 시계열 데이터 예지보전 기술

해당 기술을 적용하고자 하는 분야에 대해, 시계열 데이터의 네 가지 주요 성분인 추세성, 순환성, 계절성, 불규칙성과 더불어 사전 대응을 위해 예측이 필요한 시점 등 여러 가지 요소들에 대한 깊은 분석이 선행되어야 한다는 점에 주의해야 할 것이다.

VI. 결론

본고에서는 다양하고 많은 이기종 통신 장비들로 구축되어 있어 유지관리 복잡도가 매우 높은 통신사업자의 대규모 유무선 통신망에서 장애 사전 예방을 위한 통신사업자의 노력과 이를 해결하기 위한 예지보전 AI 기술의 적용 방안에 대해 알아보았다. 먼저, 장애 관제를 어렵게 만드는 요소로는 상호 표준화되지 않고 제조사 종속적인 경보 메시지 형식, 그리고 설치 위치에 따른 트래픽 발생량, 커버리지 등의 운용 환경 차이를 고려해야 한다는 점이 있었다. 다음으로는 이를 해결하기 위한 전통적인 규칙 기반 장애 관제 기술에 대해, 발생 가능한 주요 경보 메시지를 사전 정의하는 방식과 고정 임계치를 활용하여 수치형 시계열 데이터의 이상을 탐지하는 방식을 살펴보았다. 마찬가지로, 더욱 진보된 AI 기반 장애 관제 기술에 대해서는 시계열 데이터의 정교한 분석과 동적 임계치 활용 방식 측면에서 알아보았다. 마지막으로 AI 기술의 발전과 함께 최근 각종 분야에서 화두가 되고 있는 예지보전 기술의 적용을 위해 동적 임계치 설정과 회귀 분석을 결합하는 방법에 대해 소개했다.

이처럼 통신사업자는 안정적인 통신망 구축과 재빠른 장애 대응을 위한 관제 지능화 업무에 많은 노력을 기울이고 있다. 기존의 통신 인프라에 대한 숙련된 운용자를 꾸준히 양성하는 것도 중요하지만, 거대한 잠재력을 가진 AI 기술에 대해 열린 사고를 가지는 것이 선행되어야 한다. 하루가 다르게 무서운 속도로 발전해 나가는 AI 기술을 통신 분야에서도 하나의 응용으로써 기존의 도메인 지식을 어떻게 결합하면 좋을지 깊은 고민이 필요한 중요한 시점인 것이다.

참고 문헌

- [1] 김은도 등, "전송망 이기종 네트워크 장비들로부터 발생하는 장애 정보에 대한 딥러닝 기반 통합 분류 모델 구현," 한국통신학회 학술대회논문집, pp. 886-887, 2022.
- [2] R. D. Gardner et. al., "Methods and systems for alarm correlation," Proc. GLOBECOM, pp. 136-140, 1996.

- [3] 최성만 등, "프레임워크 기반 성능관리 도구를 이용한 효율적인 네트워크 트래픽 관리," 정보과학회 컴퓨팅의 실제 논문지, Vol. 11, Issue 3, pp. 224-234, 2005.
- [4] R. N. Cronk et. al., "Rule-based expert systems for network management and operations: an introduction," IEEE Network, Vol. 12, Issue 5, pp. 7-21, 1988.
- [5] F. Wuhib et. al., "Decentralized service-level monitoring using network threshold crossing alerts," IEEE Communications Magazine, Vol. 44, Issue 10, pp. 70-76, 2006.
- [6] H. Wang et. al., "Progress in Outlier Detection Techniques: A Survey," IEEE Access, Vol. 7, pp. 107964-108000, 2019.
- [7] E. B. Dagum, "Time series modeling and decomposition," Statistica, Vol. 70, Issue 4, pp. 433-457, 2010.
- [8] N. Alkhamees et. al., "Event detection from time-series streams using directional change and dynamic thresholds," IEEE International Conference on Big Data, pp. 1882-1891, 2017.
- [9] 김한주 등, "실시간 수치 데이터 이상검출 감지," 한국정보과학회 한국컴퓨터종합학술대회 논문집, pp. 1658-1660, 2020.
- [10] B. Zong et. al., "Deep Autoencoding Gaussian Mixture Model for Unsupervised Anomaly Detection," International conference on learning representations, 2018.
- [11] B. Kedem et. al., "Regression models for time series analysis," John Wiley & Sons, 2005.

약 력



김은도

2012년 한양대학교 응용물리학 이학사
2018년 UST 네트워크공학 공학박사
2018년~현재 KT 융합기술원 인프라DX연구소 책임연구원
관심분야: AI 기반 네트워크 지능화 기술, 데이터 사이언스
코어 기술